

UNIVERSIDAD DE CARABOBO

Facultad Experimental de Ciencia y Tecnología
Departamento de Computación

Electiva: Aprendizaje Automático

ASIGNACIÓN 1 DEL PROYECTO
Análisis Exploratorio de Datos (EDA)Profesor: Álvaro Espinoza
2026

Fecha de entrega: 18 de agosto de 2026

1. Propósito

Realizar un análisis exploratorio de datos completo, reproducible y argumentado sobre el dataset asignado. El EDA debe permitir comprender cómo está construido el conjunto de datos, qué representa cada observación, qué problemas de calidad existen, cuáles patrones son relevantes y qué decisiones deberán validarse posteriormente durante el modelado.

Principio rector

El EDA del Titanic es una referencia de estructura y nivel de razonamiento, no una plantilla para copiar. Ningún dataset es idéntico a otro. Se evaluará que cada estudiante adapte las preguntas, validaciones, gráficos e ingeniería de variables a su propio problema.

2. Único entregable

Entregable	Condiciones obligatorias
Notebook ejecutado y listo para ejecutar	Un único archivo <code>.ipynb</code> , con todas las celdas ejecutadas en orden, sin errores, con tablas, gráficos y resultados visibles. Al reiniciar el kernel y ejecutar <i>Run All</i> , el notebook debe reproducir el análisis completo.

No se solicita informe separado, exportación HTML/PDF, README ni presentación. Toda la explicación, evidencia e interpretación debe estar contenida en el notebook.

3. Requisitos generales del notebook

De acuerdo con las orientaciones desarrolladas en clase, el notebook deberá cumplir lo siguiente:

- Estar redactado completamente en **inglés**: títulos, comentarios relevantes, interpretaciones y conclusiones.
- Comenzar con un **membrete**, el logo de la Facultad, el título del análisis y una descripción breve del problema.
- Combinar celdas de código con celdas Markdown. No debe ser una sucesión de código sin explicación.

- Presentar conclusiones después de cada bloque importante. Una tabla o un gráfico sin interpretación no constituye análisis.
- Usar nombres claros, código ordenado y salidas legibles. Deben evitarse celdas innecesarias, duplicadas o ejecutadas fuera de orden.
- Conservar todas las salidas finales visibles al entregar el archivo.

4. Estructura orientativa del EDA

La siguiente organización debe reconocerse en el notebook, aunque los títulos, el orden y la profundidad pueden cambiar cuando el dataset lo justifique.

4.1 Contexto y definición del problema

- Explicar el dominio, la pregunta que motiva el proyecto y la utilidad esperada.
- Definir la **unidad de observación**: qué representa una fila después de construir el dataset final.
- Identificar la variable objetivo, si existe, su significado y el tipo de problema de aprendizaje automático.
- Explicar las clases en problemas de clasificación y aclarar si el problema es binario, multiclase o multietiqueta.

4.2 Preguntas guía

Antes de explorar, formular preguntas concretas que dirijan el notebook. Por ejemplo:

- ¿Qué variables contiene el dataset y cuál es su rol analítico?
- ¿Existen valores faltantes, duplicados, categorías raras o valores sospechosos?
- ¿Cómo se distribuye la variable objetivo?
- ¿Qué variables muestran asociaciones relevantes con el objetivo?
- ¿Existen relaciones, redundancias o interacciones entre predictores?
- ¿Qué información adicional puede construirse a partir de las variables originales?

Las preguntas deben adaptarse al dataset. No se exige utilizar literalmente las preguntas del Titanic.

4.3 Configuración y reproducibilidad

El notebook debe incluir al inicio una sección de configuración con:

- todas las importaciones principales agrupadas;
- rutas relativas o una estrategia reproducible de localización de los datos;
- semilla aleatoria cuando exista cualquier operación estocástica;
- opciones de visualización que faciliten la lectura de tablas y gráficos.

4.4 Construcción y carga del dataset

Algunos proyectos parten de varios archivos, tablas o fuentes. Cuando corresponda, realizar y documentar las siguientes acciones:

- leer todas las fuentes necesarias;
- explicar las llaves y criterios utilizados para unirlos;

- justificar filtros, agregaciones o cambios de granularidad;
- verificar que la tabla final tenga la unidad de observación declarada;
- comprobar que las uniones no generen duplicados o pérdida inesperada de registros.

Esta etapa forma parte del EDA y debe ser comprensible para otra persona que ejecute el notebook.

Datos temporales y secuenciales

Algunos datasets describen observaciones ordenadas en el tiempo o secuencias de eventos. En estos casos, identificar la variable temporal, convertirla al formato correcto, ordenar los registros, revisar frecuencia, intervalos, huecos, tendencias, estacionalidad y posibles cambios de régimen. También evitar mezclas aleatorias o transformaciones que utilicen información futura, ya que pueden producir fuga de información temporal. El análisis debe respetar el orden natural de la secuencia.

4.5 Inspección estructural y roles analíticos

Mostrar, como mínimo, dimensiones, primeras observaciones, nombres de columnas, tipos almacenados, valores únicos y valores faltantes. Además, distinguir entre el tipo de pandas y el **rol analítico** de la variable:

- identificador;
- numérica continua o discreta;
- categórica nominal u ordinal;
- fecha/hora, texto, geográfica u otro tipo específico del dominio.

Una variable numérica no debe considerarse automáticamente una medida útil: puede ser un identificador o una categoría codificada.

4.6 Calidad de los datos

El diagnóstico debe construirse según el dominio e incluir, cuando aplique:

- valores faltantes en cantidad y porcentaje;
- filas duplicadas y duplicados en identificadores o llaves;
- rangos imposibles, valores negativos no permitidos o categorías fuera del dominio;
- cardinalidad, categorías raras, errores tipográficos y formatos inconsistentes;
- valores extremos, diferenciando un caso válido de un posible error;
- patrones de ausencia y su posible asociación con otras variables.

Después de presentar las verificaciones, incluir una síntesis escrita de los problemas encontrados y sus posibles implicaciones. No se deben eliminar o imputar observaciones de manera automática ni sin justificación.

4.7 Análisis univariado

Describir las variables relevantes con estadísticas y gráficos adecuados a su naturaleza:

- para variables numéricas: centro, dispersión, forma, asimetría y extremos;
- para variables categóricas: frecuencias, proporciones y cardinalidad;
- para fechas, texto u otras estructuras: análisis específico al tipo de información.

Antes de agrupar una variable continua en intervalos, debe examinarse su distribución original y justificarse la elección de los cortes.

4.8 Variable objetivo

Cuando exista una variable objetivo, analizarla explícitamente:

- significado de sus valores o clases;
- conteos y proporciones;
- balance o desbalance;
- referencia ingenua o *baseline* basada en la clase mayoritaria, cuando corresponda.

El baseline no constituye el modelo final; sirve para establecer una referencia mínima para la etapa posterior.

4.9 Análisis bivariado y multivariado

Examinar relaciones relevantes entre variables y, cuando corresponda, respecto al target:

- comparar grupos mediante conteos, porcentajes, tasas o distribuciones;
- mostrar siempre tamaños de muestra para evitar conclusiones basadas en grupos diminutos;
- estudiar correlaciones, redundancias y relaciones no lineales;
- incluir al menos una interacción o segmentación que aporte información adicional al análisis individual;
- distinguir claramente asociación de causalidad.

4.10 Ingeniería exploratoria de variables

Proponer o construir variables que tengan sentido para el dataset: componentes de fechas, proporciones, agregaciones, tamaños de grupo, categorías consolidadas, atributos extraídos de texto u otras transformaciones. Cada nueva variable debe incluir:

- definición y procedimiento de construcción;
- intuición o información que intenta capturar;
- evidencia exploratoria de su posible utilidad;
- limitaciones o posible redundancia con variables existentes.

No se espera copiar `family_size`, `title` o `deck`; se espera construir las variables que el dataset asignado realmente necesite.

4.11 Conclusiones, limitaciones y hoja de ruta

El notebook debe terminar con:

- resumen de los hallazgos principales;
- problemas de calidad que deberán tratarse;
- variables, relaciones e interacciones potencialmente importantes;
- limitaciones, sesgos, grupos pequeños y preguntas abiertas;
- hipótesis de limpieza, imputación, codificación, transformación o selección que deberán validarse durante el modelado.

Las decisiones finales de preprocesamiento no se consideran demostradas por el EDA. Además, cualquier imputador, codificador, escalador o selección aprendida deberá ajustarse únicamente con los datos de entrenamiento para evitar *data leakage*.

5. Visualizaciones e interpretación

- Cada gráfico debe responder una pregunta y tener título, ejes, unidades y leyenda cuando corresponda.
- El tipo de gráfico debe seleccionarse según el mensaje que se desea comunicar. No existe una cantidad mínima artificial de gráficos.
- Deben evitarse gráficos decorativos, redundantes, ilegibles o incluidos únicamente para alargar el notebook.
- Las tablas y gráficos importantes deben ir acompañados por una conclusión: **qué se observa, por qué importa y qué precaución requiere**.
- Se permite apoyarse en herramientas de IA para generar o mejorar código, pero el estudiante debe comprenderlo, verificarlo y poder explicarlo.

Uso recomendado de inteligencia artificial

Se permite y se recomienda utilizar herramientas de IA como apoyo para comprender variables desconocidas, proponer verificaciones de calidad, seleccionar visualizaciones, depurar código y explorar métodos específicos del dataset. La IA debe funcionar como asistente, no como sustituto del razonamiento: verificar el código y los resultados, adaptar las propuestas al dominio, escribir interpretaciones basadas en la evidencia obtenida y estar en capacidad de explicar cada decisión incluida en el notebook.

Criterio de profundidad

El ejemplo del Titanic muestra el nivel mínimo de razonamiento esperado. El proyecto asignado puede requerir pasos adicionales, especialmente en la construcción de la tabla analítica, el tratamiento de fechas o texto, las validaciones de dominio y la creación de variables propias. Se espera ir más allá del ejemplo cuando el problema lo requiera.

6. Rúbrica de evaluación

Criterio	Pts.	Evidencia esperada
Contexto, preguntas y construcción del dataset	15	Problema, unidad de observación, target, preguntas guía y proceso de construcción correctamente explicados.
Estructura y calidad de datos	15	Roles analíticos, ausencia, duplicados, cardinalidad, rangos y verificaciones específicas del dominio.
Análisis univariado y del target	15	Distribuciones, resúmenes, balance y baseline adecuados al problema.
Análisis de relaciones e interacciones	20	Comparaciones relevantes, tamaños de muestra, redundancias, interacciones e interpretación prudente.
Ingeniería exploratoria	10	Variables derivadas justificadas y específicas del dataset asignado.
Visualización e interpretación	15	Gráficos útiles y legibles; cada bloque importante termina con hallazgos respaldados por evidencia.
Conclusiones, limitaciones y hoja de ruta	5	Síntesis clara, hipótesis para modelado y prevención de fuga de información.
Idioma, reproducibilidad y presentación	5	Notebook en inglés, ejecutado, ordenado, sin errores y listo para <i>Run All</i> .
Total	100	

7. Checklist antes de entregar

- ☐ Redactar el notebook completamente en inglés e incluir membrete y logo.
- ☐ Definir el problema, las preguntas guía y la unidad de observación.
- ☐ Documentar la construcción de la tabla final a partir de las fuentes originales.
- ☐ Diferenciar los tipos almacenados de los roles analíticos.
- ☐ Revisar ausencia, duplicados, cardinalidad, rangos y reglas del dominio.
- ☐ Analizar distribuciones, target, relaciones e interacciones pertinentes.
- ☐ Respetar el orden temporal o secuencial de los datos cuando corresponda.
- ☐ Incluir conclusiones después de cada bloque importante.
- ☐ Construir variables derivadas específicas, sin copiar mecánicamente el ejemplo del Titanic.
- ☐ Diferenciar asociación, hipótesis y decisiones que deberán validarse.
- ☐ Reiniciar el kernel, ejecutar *Run All* y conservar visibles todas las salidas.

La extensión del EDA debe estar determinada por las preguntas del dataset, no por una cantidad artificial de celdas o gráficos.